



L'outil MonProjetSup - Avenir(s) : données et calculs

Ce document technique détaille les sources de données et méthodes de calcul utilisées par l'outil MonProjetSup de la plateforme Avenir(s) de l'Onisep, dénommé « MPS » dans la suite du document.

Le code source de MPS est consultable à l'adresse de publication interministérielle suivante : <https://github.com/betagouv/monprojetsup>.

Le présent document poursuit une finalité pédagogique et est une lecture préliminaire à une lecture détaillée du code source, en particulier le module « etl¹ » qui produit les données de référence de MPS ainsi que le module « suggestions-algo² » qui est le cœur du calcul des suggestions personnalisées de MPS.

Les aspects pédagogiques et les enjeux éducatifs de MPS sont détaillés dans un document de présentation générale, appelé « document de présentation générale de MPS³ », qui explicite les finalités de la construction de l'outil MPS et comment MPS peut être utilisé comme un outil au service du dialogue entre les équipes pédagogiques des lycées et les lycéens, dès la classe de seconde, afin de les accompagner, tout au long du lycée, dans la construction progressive de leur projet d'orientation post-bac.

Les méthodes de calcul utilisées par MPS pour générer les suggestions personnalisées sont le fruit de choix effectués selon plusieurs critères, identifiés lors du dialogue avec différentes parties prenantes du projet : les lycéens et leurs parents, les institutions porteuses du projet (MESR et Onisep) qui portent des enjeux de politique publique détaillés dans le document de présentation générale, les équipes éducatives des lycées ainsi que deux groupes de spécialistes : le groupe des experts métiers et le groupe des experts scientifiques.

Le groupe des experts scientifiques est constitué de chercheurs et enseignants experts qui évaluent d'un point de vue scientifique et technique la pertinence du fonctionnement de MPS, en particulier la formulation de suggestions personnalisées, et ce dès la phase de conception. La mission d'animation du groupe des experts

¹ <https://github.com/betagouv/monprojetsup/tree/demo/app/etl>

² <https://github.com/betagouv/monprojetsup/tree/demo/app/suggestions/suggestions-algo>

³ « Document de présentation de l'outil MonProjetSup - Avenir(s) un outil au service du dialogue entre lycéens et équipes éducatives sur l'orientation postbac »

scientifiques et de synthèse des travaux a été confiée par le MESR à deux enseignants-chercheurs du LaBRI⁴, qui ont également été moteurs dans l'implémentation des modules « etl » et « suggestion-algos ».

La conception des interfaces graphiques de MPS et la production de l'application web a été effectuée dans le cadre de la startup d'Etat éponyme⁵, en se basant sur un prototype initialement développé au LaBRI et testé dans plusieurs lycées de l'académie de Bordeaux, avec le soutien du MESR, de la DGESIP et de la DRAIO de Nouvelle-Aquitaine⁶.

I. Sources de données

Cette section détaille les différentes sources de données utilisées pour alimenter les contenus de l'outil MPS.

1. Données Parcoursup

Les données de Parcoursup sont exploitées pour produire le référentiel des formations postbac et fournir aux lycéens, de la seconde à la terminale, des informations leurs permettant de mieux comprendre les attendus des formations postbac.

La base du référentiel des formations est constituée de l'offre de formation disponible sur Parcoursup, chaque formation Parcoursup correspondant à un triplet d'affectation correspondant à un établissement d'inscription, un établissement d'accueil et une commission d'examen des vœux (indexation par g_ta_cod).

On retrouve la même base d'indexation dans l'open data Parcoursup publiée annuellement par le SIES (voir <https://data.enseignementsup-recherche.gouv.fr/pages/parcoursupdata/>), où chaque ligne correspond à un g_ta_cod.

Les formations Parcoursup sont regroupées par type de formation en exploitant les clés g_fl_cod et g_fr_cod, correspondant dans l'open data du SIES aux clés « filière de formation détaillée » et « filière de formation très agrégée ». Chaque regroupement correspond à une « formation MPS », matérialisé dans l'outil sous forme d'une fiche formation, il en existe de l'ordre de 500. Deux regroupements peuvent s'intersecter, c'est le cas par exemple du regroupement PPPE⁷ et de certaines licences.

Le choix des regroupements effectués vise à obtenir une bonne représentativité de l'offre de formation, afin de permettre aux lycéens de prendre connaissance de l'ensemble des possibilités postbac offertes sur Parcoursup, sous la forme de fiches formations suffisamment synthétiques pour permettre au lycéen d'explorer efficacement l'éventail des formations susceptibles de l'intéresser. Chaque fiche synthétique MPS est également un point d'entrée vers des informations plus détaillées disponibles sur Parcoursup et la plateforme Avenir(s).

⁴ Laboratoire Bordelais de Recherche en Informatique <https://www.labri.fr/>

⁵ <https://beta.gouv.fr/startups/monprojetsup.html>

⁶ https://www.ac-bordeaux.fr/region_academique

⁷ <https://www.google.com/search?client=safari&rls=en&q=PPPE&ie=UTF-8&oe=UTF-8>

Le référentiel obtenu est différent du référentiel IDEO des formations développé par l'ONISEP, qui référence essentiellement les diplômes accessibles dans l'enseignement supérieur, alors que le référentiel des formations utilisé dans MPS et Parcoursup référence l'ensemble des points d'entrée dans l'enseignement supérieur.

Les données fournies par les établissements au sujet de leurs attendus et critères d'admission sont également compilées, notamment les attendus nationaux définis par arrêté du ministre chargé de l'enseignement supérieur et les principaux éléments utilisés par les commissions d'examen des vœux pour examiner les candidatures des candidats.

Pour chaque formation du référentiel MPS, les données de la dernière campagne d'admission Parcoursup sont exploitées afin de calculer des indicateurs statistiques permettant de caractériser les profils des lycéens qui ont accepté définitivement une proposition d'admission pour une formation référencée sur Parcoursup.

Le périmètre des candidats Parcoursup pris en compte dans la production des statistiques est le même que celui utilisé pour produire les statistiques disponibles sur

FORMATION

BTS - Conception de produits industriels

1000 lycéens ont intégré cette formation l'année dernière

Formation disponible dans 102 ville(s) dont Lormont • Bordeaux • Saintes
[Voir sur la carte Parcoursup](#)

♥ Ajouter à ma sélection

🗖 Ne plus voir

La formation

Critères d'admission

Nos conseils

Cette formation prévoit un nombre de places priorisé pour les bacheliers professionnels. Elle accueille également des profils variés issus de la voie générale et technologique. Pour réussir pleinement dans la formation, il est important que les lycéens vérifient que les connaissances et compétences...

[Lire la suite](#)

Cette formation est aussi réalisable en alternance
La formation en alternance te permet d'étudier et de travailler en même temps.

[En savoir plus](#)

Exemples de métiers accessibles via cette formation

Designer/euse industriel/le

Dessinateur/trice en construction mécanique

Formateur/trice technique en agroéquipement

Technicien/ne électrotechnicien/ne

Technicien/ne prototypiste en agroéquipement

FORMATION

BTS - Conception de produits industriels

1000 lycéens ont intégré cette formation l'année dernière

Formation disponible dans 102 ville(s) dont Lormont • Bordeaux • Saintes
[Voir sur la carte Parcoursup](#)

♥ Ajouter à ma sélection

🗖 Ne plus voir

La formation

Critères d'admission

Nos conseils

Répartition par filières de bacs

BAC STI2D 53%

BAC PROFESSIONNEL 35%

BAC GÉNÉRAL 11%

Les principaux points examinés dans les candidatures

- ✓ Résultats académiques (34%)
- ✓ Motivation, connaissance (19%)
- ✓ Savoir-être (17%)
- ✓ Compétences académiques (16%)

Moyenne générale des lycéens admis à la formation (Bac Général)



[Version texte du graphique](#)

Les attendus de la formation

S'intéresser à la conception de produits mécaniques
Disposer de compétences pour travailler en équipe dans le cadre d'une démarche de projet
Disposer de capacités d'organisation et d'autonomie
Disposer de compétences scientifiques et technologiques pour Interpréter et exploiter...

[Lire la suite](#)

Cette formation est aussi réalisable en alternance
La formation en alternance te permet d'étudier et de travailler en même temps.

[En savoir plus](#)

la carte des formations de Parcoursup. Il s'agit essentiellement des candidats inscrits sur Parcoursup, scolarisés au lycée ou préparant un diplôme de fin d'études secondaires en Europe, domiciliés en Europe ou scolarisés dans un lycée français à l'étranger (AEFE), et qui ont accepté définitivement une proposition sur Parcoursup.

Pour chaque formation du référentiel MPS, on calcule dans cette population de candidats Parcoursup la distribution statistique de plusieurs variables : la filière (générale, techno, pro) des lycéens admis, leurs enseignements de spécialités (pour les bacheliers des filières générales et technologiques) et, pour les bacheliers de la filière professionnelle, la spécialité de baccalauréat professionnel préparée, et leurs moyennes générales.

Ces données sont ensuite restituées aux lycéens et équipes pédagogiques via les fiches formations, voir exemple dans l'encadré ci-dessus.

2. Données IDEO/ONISEP

Les données IDEO fournies en open data par ONISEP (<https://opendata.onisep.fr/>) sont exploitées afin de construire le référentiel des métiers, des domaines professionnels, des centres d'intérêts et leurs liens avec les formations.

Le référentiel des métiers est récupéré depuis <https://opendata.onisep.fr/data/5fa5949243f97/2-ideo-metiers-onisep.htm> et <https://opendata.onisep.fr/data/5fe0808a2da6f/2-ideo-fiches-metiers.htm> , incluant le contenu éditorial, les liens vers des ressources documentaires externes, et les associations avec les formations, les domaines et centres d'intérêts.

Le référentiel des formations est récupéré depuis <https://opendata.onisep.fr/data/5fa591127f501/2-ideo-formations-initiales-en-france.htm> et <https://opendata.onisep.fr/data/5fe07a9ecc960/2-ideo-fiches-formations.htm>, incluant le contenu éditorial, les liens vers des ressources documentaires externes, et les associations avec les métiers, les domaines et centres d'intérêts.

L'équipe data de l'Onisep fournit une table de correspondance entre le référentiel IDEO des formations initiales et le référentiel des filières Parcoursup. Cette correspondance est régulièrement mise à jour et exploitée dans MPS mais également dans la carte des formations de Parcoursup accessible sur le site parcoursup.gouv.fr. L'équipe data de l'Onisep fournit également des correspondances supplémentaires entre domaines, formations et métiers.

Les thèmes et domaines professionnels IDEO (indexés par des clés du type T-IDEO2) sont agrégés en deux niveaux de regroupement dans des catégories et des sous-catégories afin de faciliter le choix par le lycéen des thèmes qui l'intéressent le plus. Finalement, chaque sous-catégorie est constituée d'un ensemble de plusieurs clés T-IDEO2, et on passe ainsi de 133 clés T-IDEO2 à 46 sous-domaines MPS regroupés en 14 catégories.

La même opération d'agrégation en deux niveaux est réalisée sur les centres d'intérêts.

3. Données France Travail

Les données ROME France Travail disponibles en open data (<https://www.francetravail.org/opendata/repertoire-operationnel-des-meti.html?type=article>) sont utilisées pour récupérer les données croisées entre métiers et centre d'intérêts, et fournir des liens vers des ressources externes vers les fiches métiers « France Travail ».

4. Données MPS

La communauté des experts métiers MPS, constituée de plus d'une centaine d'experts en orientation, produit des données de référence sur l'orientation post-bac utilisées par MPS. Les experts testent MPS à chaque itération d'amélioration, formulent des recommandations sur l'amélioration de l'outil et valident la pertinence des suggestions personnalisées. Les experts se connectent également à l'application afin de produire des exemples variés de profils de référence lycéen, incluant un choix cohérent de domaines, de favoris formations et de favoris métiers.

Le mode opératoire est décrit dans ce document <https://monprojetsup.fr/guide-a-destination-des-experts-metiers/>.

Les lycéens utilisant MPS produisent également des données qui sont exploitées pour déterminer les combinaisons fréquentes de choix de formations, domaines et métiers.

Enfin, chaque fiche formation inclut un descriptif court qui a été produit par l'équipe de développement MPS et les services de la DGESIP, rédigé avec un ton qui vise à donner aux lycéens potentiellement intéressés par la formation envie d'en savoir plus.

II. Génération des suggestions personnalisées

1. Généralités

Les suggestions personnalisées émises par l'outil MPS ont pour objectif de fournir à chaque élève une liste ordonnée de formations MPS, classées selon leur pertinence par rapport aux intérêts, préférences exprimées par l'élève lui-même lors de la constitution de son profil scolaire. Ces suggestions doivent permettre d'élargir les horizons des élèves et de favoriser le dialogue avec le professeur principal et l'équipe éducative du lycée.

Les méthodes de calcul sélectionnées pour générer les suggestions personnalisées répondent à une double exigence de simplicité et d'évolutivité.

Ces méthodes doivent être simples, transparentes et facilement explicables, afin de garantir, pour les usagers, une compréhension claire du fonctionnement de MPS.

Les méthodes doivent être également suffisamment flexibles pour évoluer sans nécessiter de modifications majeures. Cela implique la capacité d'ajouter de nouveaux scores de pertinence, d'intégrer de nouvelles sources d'information, et d'ajouter automatiquement de nouvelles formations.

2. Expression par chaque lycéen de ses préférences et de son profil

L'accès des lycéens à l'outil MPS s'effectue via la plateforme Avenir(s) dans le cadre de séquences pédagogiques organisées par les enseignants.

Chaque élève qui s'inscrit dans la démarche MPS au sein de son lycée est invité à renseigner plusieurs types d'informations, organisées en trois catégories :

- Sujets d'intérêt :
 - Mots-clés
 - Métiers envisagés
 - Formations envisagées
- Préférences :
 - Durée des études
 - Localisation des établissements de formation
 - Intérêt pour les cursus en alternance
- Profil scolaire :
 - Classe actuelle (seconde / première / terminale)
 - Filière de bac
 - Spécialités/enseignements de spécialité choisis ou envisagés

3. Ordre d'affichage des suggestions personnalisées

Le calcul des suggestions personnalisées de MPS se base sur les informations de profil renseignée par chaque lycéen afin de lui présenter la liste des formations MPS dans un ordre personnalisé qui est déterminé sur la base de deux principes :

- prioriser les formations les plus pertinentes au regard des préférences du lycéen et de son profil scolaire,
- favoriser la variété des suggestions personnalisées afin d'élargir l'éventail des choix offerts à chaque lycéen et de lutter contre les mécanismes d'autocensure.

Ces principes sont implémentés par un calcul qui prend comme données d'entrée les préférences et le profil renseignés par le lycéen et se décompose en trois étapes : le calcul d'un ensemble de « scores de pertinence », leur agrégation en un score global de pertinence, et enfin l'application d'un critère de variété des résultats.

Pour chaque élève et formation MPS, un ensemble de scores de pertinence sont calculés pour apprécier la pertinence de faire la suggestion correspondante à cet élève. Ces scores sont calculés en valorisant les données de Parcoursup, Onisep et MPS.

Par exemple le score de proximité géographique est basé sur la localisation des établissements de formation et les villes préférées renseignées par le lycéen lui-même. Autre exemple, les données de référence des experts métiers sont exploitées par l'intermédiaire d'un algorithme d'apprentissage supervisé.

Le détail de ces différents scores de pertinence et de leur calcul est renseigné dans la section III.

Une fois calculés, les scores de pertinence sont ensuite agrégés en un score unique. Cette agrégation doit refléter au mieux les recommandations des experts métiers sur la priorité à donner aux critères individuels de pertinence, et les retours des utilisateurs lors des campagnes de beta-tests organisés par l'Onisep.

Par exemple, un score de satisfaction des centres d'intérêt de l'élève peut être considéré plus prioritaire qu'un score de proximité géographique.

La méthode d'agrégation et le choix des paramètres utilisés pour l'agrégation sont détaillés dans la section IV.

Enfin, l'application du critère de variété est détaillé dans la section V.

III. Calcul des scores de pertinence

Cette section détaille le calcul des différents scores de pertinence, sur la base des informations de profils fourni par le lycéen.

1. Score de proximité géographique

Le score de proximité géographique est calculé sur la base d'un principe simple:

- le score est maximum si la formation considérée est dispensée dans un rayon de 10 km autour d'une des villes préférées du lycéen.
- au-delà de 10km, le score décroît de manière inversement proportionnelle à la distance en km.

La localisation des lieux de formation est basée sur les données de la carte des formations Parcoursup de l'année en cours, qui intègre la géolocalisation des formations. L'existence de transports en commun n'est pas prise en compte, c'est une évolution envisagée pour une version ultérieure.

Les villes expriment une préférence et les formations proches de ces villes sont priorisées dans les suggestions. Mais tout reste ouvert et le lycéen n'est pas enfermé dans un choix territorial effectué a priori, avant d'avoir exploré l'offre de formations grâce à MPS. La fonction de sélection des établissements et la carte des formations Parcoursup permettent de cerner plus précisément l'offre au sein d'un territoire, après avoir effectué l'exploration.

2. Score de proximité au profil scolaire des admis (filière de bac)

Par filière de baccalauréat, on entend : filière générale, filière technologique et filière professionnelle.

Le score de proximité avec la filière de bac est calculé sur la base du principe suivant :

- le score est maximum si au moins 20% des admis dans la formation sont originaires de la même filière de bac que le lycéen.

- le score est minimum si moins de 1% des admis dans la formation sont originaires de la même filière de bac que le lycéen.

- entre ces deux valeurs le score décroît de manière linéaire.

Les données utilisées pour ce calcul sont les données statistiques décrites dans la section 1 « Données Parcoursup ». Le mode de calcul a été ajusté en prenant en compte les recommandations des experts métiers, notamment en ce qui concerne les biais liés à la représentativité des profils.

3. Score de proximité au profil scolaire des admis (spécialités)

Le score de proximité avec les spécialités choisies ou envisagées est calculé sur la base du principe suivant :

Pour chaque spécialité choisie ou envisagée par le lycéen, on considère le pourcentage de lycéens ayant choisi cette même spécialité parmi les lycéens qui ont accepté cette formation l'année précédente sur Parcoursup. On fait la somme de ces pourcentages.

- le score est maximum si la somme atteint 100% ou plus

- le score est minimum si la somme est à 0%.

Les données utilisées pour ce calcul sont les données statistiques décrites dans la section « Données Parcoursup ». Le mode de calcul a été ajusté en prenant en compte les recommandations des experts métiers, notamment en ce qui concerne les biais liés à la représentativité des profils.

4. Score de conformité à la durée envisagée des études

Le score de conformité avec la durée envisagée des études est calculé sur la base des principes suivants :

Dans les cas où le lycéen a exprimé une préférence pour les études courtes :

- le score est maximum si la formation considérée est une formation en 1 an

- le score est minimum si la formation considérée est une formation menant à un parcours d'études durant plus de 3 ans.

Dans les cas où le lycéen a exprimé une préférence pour les études longues :

- le score est minimum si la formation considérée est une formation menant à un parcours d'études en 3 ans ou moins.

- le score est maximum si la formation considérée est une formation menant à un parcours d'études en 5 ans ou plus.

Le détail de l'estimation de la durée du parcours d'étude en fonction du type de formation postbac est consultable dans le code source. Par exemple, pour toutes les licences, cette durée est fixée à 5 ans, exceptées les licences pro. en effet, bien que la durée d'obtention du diplôme de licence soit de 3 ans, la plupart des étudiants

poursuivent ensuite en master, et la durée totale de leurs études est typiquement de 5 ans.

5. Score de conformité avec l'intérêt pour un cursus en alternance

Si le lycéen a exprimé un intérêt fort pour une formation en alternance, le score est maximum si la formation considérée existe en alternance et minimum si la formation n'existe pas en alternance.

6. Proximité aux centres d'intérêts, formations et métiers sélectionnés par le lycéen

Trois scores de proximité avec les centres d'intérêt, formations et métiers sont calculés.

Le premier valorise la base des données de référence IDEO fournies par Onisep, le second score valorise les données de référence des experts métiers et le troisième les paniers élèves présents dans la base de données MonProjetSup.

Valorisation des données de référence IDEO/Onisep

Le score de proximité aux centres d'intérêt et les formations et métiers en favoris est calculé sur la base du principe suivant.

Pour chaque centre d'intérêt, formation ou métier en favoris, on calcule la distance dans le graphe construit sur la base des données de référence IDEO fournies par Onisep, augmenté par des indexations ad-hoc, et dont les arêtes sont pondérées en fonction du type de correspondance.

Le score d'un « chemin » est le produit des poids de ses arêtes. Le score est obtenu en additionnant la somme des scores des différents « chemins ».

Le détail de ce calcul est consultable dans le code source⁸.

Valorisation des données de référence produites par les experts métiers

Pour le calcul de ce « score de pertinence », nous nous intéressons aux statistiques des profils élèves créés par les experts métiers.

Nous utilisons les paniers des élèves afin de calculer un score de pertinence entre le profil d'un élève et les formations. Ce score est calculé avec une approche statistique.

Un panier élève est constitué de différentes caractéristiques :

- les idées de métiers qu'il a envisagés,
- les idées de métiers qu'il a explicitement exclus,
- les idées de formations qu'il a envisagées,
- les idées de formations qu'il a explicitement exclues,
- les centres d'intérêts de l'élève,

⁸ Voir <https://github.com/betagouv/monprojetsup/blob/demo/app/suggestions/suggestions-algo/src/main/java/fr/gouv/monprojetsup/suggestions/algo/AffinityEvaluator.java#L549>

- les mots-clés associés à ces centres d'intérêts.

Le score de pertinence entre un élève, représenté par un ensemble de caractéristiques $c_1, c_2, \dots, c_k$, et une formation F est donné par la probabilité conditionnelle suivante :

$$P(F | c_1, c_2, \dots, c_k)$$

Cette probabilité est estimée en faisant une hypothèse couramment utilisée en apprentissage automatique et en statistique, appelée l'hypothèse bayésienne naïve⁹, selon laquelle les caractéristiques sont conditionnellement indépendantes :

$$P(F | c_1, c_2, \dots, c_k) \approx \frac{P(F) \prod_{i=1}^k P(c_i | F)}{P(c_1, c_2, \dots, c_k)}$$

Observons que le dénominateur est constant pour toutes les formations, et donc ne change pas l'ordre de préférence des formations. Nous pouvons donc ignorer ce terme.

$$P(F | c_1, c_2, \dots, c_k) \propto P(F) \prod_{i=1}^k P(c_i | F)$$

Il y a principalement deux intérêts à faire cette hypothèse d'indépendance :

- il est possible d'estimer les probabilités $P(c_i | F)$ et $P(F)$ à partir d'un nombre raisonnable de paniers élèves créés par les experts métiers. Pour ça il suffit, pour chaque formation F , de compter le nombre de fois où la caractéristique c_i apparaît dans les paniers, et de diviser par le nombre total de paniers qui contiennent la formation F . Si le nombre de paniers est suffisamment grand, cette estimation est fiable. Si le nombre de paniers est trop petit, les probabilités sont lissées à l'aide d'un processus de régularisation.
- il est possible de donner une explication à la suggestion d'une formation, en exhibant les caractéristiques qui ont le plus contribué au score de pertinence.

Valorisation des paniers élèves

Ce score est calculé avec la même technique que celle utilisée pour le score de proximité aux recommandations des experts métiers. Cependant, cette fois-ci, le score n'est pas calculé sur les profils créés par les experts métiers mais sur tous les profils élèves créés sur l'outil MonProjetSup. Ceci permet d'obtenir des suggestions de la forme "les élèves qui vous ressemblent apprécient généralement la formation X".

III. Agrégation des scores de pertinences

Pour agréger les scores, nous proposons une approche mixte d'apprentissage de classement ("learning to rank") basée sur une fonction multiplicative, couplée aux

⁹ Voir par exemple : Hand, David J., and Keming Yu. "Idiot's Bayes—not so stupid after all?." International statistical review 69.3 (2001): 385-398

recommandations des experts métiers pour intégrer les priorités et les contraintes spécifiques du domaine.

- La partie Recommandations des experts métiers : permet d'intégrer des contraintes métiers spécifiques (par exemple prioriser le critère de proximité du profil scolaire sur le critère de préférence géographique). Ainsi, les experts métiers peuvent définir des règles de priorité, quantifiées ou non, entre les différents critères de pertinence, ou des contraintes de diversité dans les résultats.
- La partie Apprentissage de classement : permet d'utiliser les données disponibles afin d'apprendre de manière automatisée certains des paramètres de l'agrégation, tout en intégrant les contraintes définies par les experts.

Fonction d'agrégation

La fonction d'agrégation utilisée est la suivante :

$$Score_F = \prod_{i=1}^k (\beta_i(1 - x_{F,i}) + x_{F,i})$$

où :

- $x_{F,i}$ est le score normalisé (entre 0 et 1) du critère i pour la formation F .
- β_i est un paramètre à apprendre (compris entre 0 et 1), représentant l'importance du critère i lorsque le score $x_{F,i}$ est nul.

Interprétation de la fonction

Il s'agit d'un produit, qui agit alors comme une conjonction entre les différents critères de pertinence, plutôt qu'une somme comme le ferait une régression logistique, qui agirait alors comme une disjonction.

- Lorsque $x_{F,i} = 1$ (le critère i est pleinement satisfait), le terme $\beta_i(1 - x_{F,i}) + x_{F,i}$ devient 1, quelle que soit la valeur de β_i . Ainsi, le critère satisfait n'affecte pas négativement le score total.
- Lorsque $x_{F,i} = 0$ (le critère i n'est pas satisfait), le terme devient β_i . Si β_i est proche de 0, le manque de ce critère réduit significativement le score total. Si β_i est proche de 1, l'absence du critère a un impact moindre.

Cette formulation permet de modéliser une conjonction entre les critères : le score total est élevé uniquement si la plupart des critères importants sont satisfaits. Les paramètres β_i permettent d'ajuster l'impact de l'absence d'un critère sur le score total.

Gestion des scores manquants

Pour un profil donné, tous les scores ne sont pas forcément disponibles. Dans ce cas, une valeur par défaut est utilisée (typiquement 0). On garantit que le score est pris en compte pour toutes les formations ou aucune, afin de comparer des vecteurs de scores comparables.

Formulation mathématique

Entraînement des paramètres β_i

Nous utilisons une approche « pairwise », réputée efficace, notamment car elle permet de générer de nombreuses données d'entraînement à partir des données disponibles.

Les N données d'entraînement sont des paires $\left(\left(x_{F_1^i}, x_{F_2^i} \right), y^i \right)_{i \in N}$ où

- $x_{F_1^i}$ et $x_{F_2^i}$ sont les vecteurs de scores des formations F_1^i et F_2^i . Ces vecteurs sont de taille k fixé, où k est le nombre de scores de pertinence.
- $y^i = 0$ si F_2^i est préférée à F_1^i dans le panier de l'élève.
- $y^i = 0.5$ si F_1^i et F_2^i sont considérées égales.
- $y^i = 1$ si F_1^i est préférée à F_2^i .

Génération des données d'entraînement

Les données sont générées à partir des paniers élèves validés ou créés par les experts métiers. Par exemple si une formation F_1 est présente positivement dans le panier de l'élève (intérêt explicite de l'élève pour cette formation), et que la formation F_2 y est présente négativement (l'élève a écarté cette formation), alors nous créons une donnée d'entraînement pour l'hypothèse $F_1 > F_2$.

Calcul du score total

Pour un élève donné, et pour chaque formation F , nous récupérons les scores normalisés des différents critères de pertinence, ce qui nous donne un vecteur de scores :

- Vecteur de scores :

$$x_F = [x_{F,1}, x_{F,2}, \dots, x_{F,k}]$$

Le score total est alors calculé à l'aide de la fonction d'agrégation. Ce score représente la pertinence globale de la formation pour l'élève, en tenant compte de la satisfaction conjointe des différents critères.

- Score total :

$$Score_F = \prod_{i=1}^k (\beta_i (1 - x_{F,i}) + x_{F,i})$$

La probabilité que la formation F_i soit préférée à la formation F_j est donnée par le modèle de Bradley-Terry¹⁰ :

¹⁰ Bradley, Ralph Allan, and Milton E. Terry. "Rank analysis of incomplete block designs: I. The method of paired comparisons." *Biometrika* 39.3/4 (1952): 324-345.

$$P(F_i > F_j) = \frac{Score_{F_i}}{Score_{F_i} + Score_{F_j}}$$

Fonction de perte à minimiser

Les paramètres β_i qui ne sont pas fixés par les experts métiers sont appris en maximisant la log-vraisemblance des données d'entraînement. La fonction de perte à minimiser est donc la log-vraisemblance négative :

$$\min_{\{\beta_i\}} L(\{\beta_i\}) = \min_{\{\beta_i\}} - \sum_{n=1}^N \left[y^{(n)} \log P(F_1^{(n)} > F_2^{(n)}) + (1 - y^{(n)}) \log P(F_2^{(n)} > F_1^{(n)}) \right]$$

Optimisation et contraintes

L'optimisation des paramètres β_i est réalisée à l'aide d'une variante classique de l'algorithme du gradient stochastique, la méthode Adam¹¹.

Données expertes. Un poids plus important est attribué aux données expertes lors de l'optimisation des paramètres β_i .

Contraintes sur les β_i :

- Pour garantir que les β_i restent dans l'intervalle $[0,1]$, nous utilisons une transformation sigmoïde.
- Nous pouvons également ajouter des contraintes métiers sur le lien entre les β_i pour refléter les priorités et les contraintes spécifiques du domaine. Par exemple : $\beta_1 > \beta_2$ pour prioriser le critère 1 sur le critère 2.

Remarques :

En cas de « cold start », c'est-à-dire lorsque peu de données sont disponibles, les valeurs des β_i sont fixées uniquement en se basant sur les données expertes. C'est le cas lors du lancement de l'outil.

IV. Variété des résultats

Le calcul des suggestions personnalisées de MPS intègre un mécanisme visant à garantir une variété dans les suggestions personnalisées de formations, comme recommandé par les experts scientifiques et les experts métiers.

Le calcul des suggestions de formations est basé en premier lieu sur un classement personnalisé des catégories de formations par score décroissant. Ce score est obtenu par agrégation de différents critères, comme présenté dans la section précédente.

Le calcul du classement personnalisé intègre également un terme de régularisation permettant de favoriser la variété. Ce terme réduit le poids des formations trop

¹¹ Diederik, P. Kingma. "Adam: A method for stochastic optimization." (2014).

similaires à celles déjà présentes dans le début du classement déjà calculé. Cela permet de réduire la redondance et de proposer une sélection de formations plus diversifiée, tout en continuant de prendre en compte le score de pertinence entre l'élève et les formations.

Pour ça, nous utilisons l'approche Maximum Marginal Relevance¹² (MMR). Les aspects métiers de la diversité sont représentés par les « types de formation ». Par exemple CPGE, BUT, Licence, CS, etc.

Pour un ensemble de suggestions S déjà sélectionnées, et une formation F non encore sélectionnée, on définit le score MMR de F vis-vis de S comme :

$$MMR(F, S) = \lambda^k \cdot Score_F$$

où k est le nombre de fois où le type de formation de F a déjà été sélectionné parmi les 10 dernières suggestions de S , et λ est un paramètre de régularisation, dont la valeur est initialement fixée selon les recommandations des experts métiers, en prenant éventuellement en compte le type de bac.

Les formations sont alors classées en utilisant un algorithme de type « glouton », c'est-à-dire qui produit la liste classée de manière incrémentale. On part d'un ensemble vide S de suggestions, et on ajoute à chaque étape la formation F qui maximise le score $MMR(F, S)$ parmi les formations non encore sélectionnées.

Le classement initialement réalisé selon les critères de pertinence est préservé en introduisant une contrainte sur le nombre maximal k de places dans l'ordre de pertinence dont une formation peut remonter lors de l'application de MMR (typiquement de 5 à 10 places maximum, en fonction des recommandations des experts métiers).

A l'avenir, il sera également possible d'affiner cette approche en intégrant d'autres critères de variété. Pour cela il suffit de définir une notion plus fine de similarité entre une formation et un ensemble de formations déjà sélectionnées. Pour l'instant, cette similarité $\text{sim}(F, S)$ correspond au nombre de formations de type identique à F déjà présentes dans les k dernières suggestions de S .

V. Références

- Bradley, Ralph Allan, and Milton E. Terry. "Rank analysis of incomplete block designs: I. The method of paired comparisons." *Biometrika* 39.3/4 (1952): 324-345.
- Diederik, P. Kingma. "Adam: A method for stochastic optimization." (2014).
- Hand, David J., and Keming Yu. "Idiot's Bayes—not so stupid after all?." *International statistical review* 69.3 (2001): 385-398

¹² Carbonell, Jaime, and Jade Goldstein. "The use of MMR, diversity-based reranking for reordering documents and producing summaries." *Proceedings of the 21st annual international ACM SIGIR conference on Research and development in information retrieval*. 1998.

- Carbonell, Jaime, and Jade Goldstein. "The use of MMR, diversity-based reranking for reordering documents and producing summaries." Proceedings of the 21st annual international ACM SIGIR conference on Research and development in information retrieval. 1998.